

Artigo Macroeconometria

Lucca Simeoni Pavan *

João Carlos de Carvalho[†]

Marcos Minoru Hasegawa[‡]

14 de fevereiro de 2017

1 Introdução

Na últimos dez anos ocorreu um grande aumento na produção e consumo de energia alternativa, sobretudo do etanol. A produção mundial do etanol quase duplicou nos últimos cinco anos. O Brasil se destaca como uns dos maiores produtores do biocombustível, segundo Departamento de Pesquisas e Estudos Econômicos (DEPEC) cerca de 30% de tudo que é produzido no mundo. O aumento da produção do etanol levanta questões importantes como a sustentabilidade dos biocombustíveis e segurança alimentar. Existe uma preocupação mundial sobre o aumento das culturas voltadas ao fato de que a produção de biocombustíveis possa causar maiores níveis e instabilidade de preços dos alimentos, principalmente devido a substituição de culturas alimentícias por plantações direcionadas a produção de biocombustíveis, geralmente culturas forrageiras como a cana-de-açúcar. As relações potenciais dos preços também podem ser exacerbadas ou enfraquecidas por políticas específicas de favorecimento, como subsídios.

A volatilidade de preços também traz custos adicionais para os participantes destes mercados, tanto produtores como consumidores. Primeiramente, os preços mais voláteis elevam os custos para agricultores gerenciar os riscos de preços, o que pode alterar as decisões entre hedge e investimento (WU; GUAN; MYERS, 2011; GARDEBROEK; HERNANDEZ, 2013). Como muitas *commodities* estão inclusas no mercado financeiro, a volatilidade também eleva o custo de gerenciamento do risco para os investidores deste setor. Já os consumidores podem ter seus níveis de bem estar frequentemente alterados, devido à instabilidade de preços, modificando constantemente sua cesta de consumo. No nível macro, Byrne, Fazio e Fiess (2013) indicam que o aumento da volatilidade dos preços agrícolas também afeta o desenho e a efetividade das políticas de estabilização de preços. Em termos gerais, a instabilidade de preços dos alimentos não é apenas uma questão de segurança alimentar.

A preocupação sobre a volatilidade dos preços dos alimentos acentua-se ao observarmos que durante o período recente de expansão dos biocombustíveis também ocorreu um rápido crescimento e aumento da instabilidade de preços de algumas *commodities* agrícolas. Porém, a priori não podemos afirmar as causas da instabilidade de preços sem uma investigação profunda. Algumas evidências empíricas sugerem que as preocupações com o biodiesel como causa dos altos e voláteis preços dos alimentos são injustificadas (CABRERA; SCHULZ, 2016) .

O recente artigo contribui sobre o assunto ao estudar as inter-relações entre preços e transmissões de volatilidades do etanol e dos produtos agrícolas no Brasil usando dados diários de janeiro de 2010 a dezembro de 2016. Pretende-se verificar se existem transbordamentos e como eles se comportam ao longo tempo . A maioria dos estudos nesta área abordam as dependências

*Doutorando em Desenvolvimento Econômico, PPDGE/UFPR - warrenjax@gmail.com

[†]Doutorando em Desenvolvimento Econômico, PPDGE/UFPR - joaocarlos_carva@hotmail.com

[‡]Professor do Departamento de Economia da UFPR e do PPGDE/UFPR

entre os níveis dos preços. A literatura sobre transmissões de volatilidade ainda é escassa. Para tanto serão utilizadas três séries temporais de *commodities*: etanol, açúcar e soja.

A escolhas das *commodities* não são ao acaso. A teoria econômica baseada em fundamentos de mercado e atividades de arbitragem sugere que os preços do etanol, soja e açúcar estão inter-relacionados (GORTER; JUST, 2007). O açúcar e etanol são relacionados, pois são produzidos a partir da mesma cultura, que é a cana-de-açúcar. Já a soja pode ser indiretamente afetada pelo aumento da demanda do etanol, principalmente pela substituição de área plantada para fins alimentícios por culturas voltadas a produção do biocombustível. O grão é umas das principais fontes de proteína vegetal, cada vez mais usada para alimentação humana. Além disso, o Brasil é um dos grandes produtores da soja, aproximadamente 30% da produção mundial. As culturas de soja e cana-de-açúcar concorrem pelo mesmo espaço territorial no Brasil, principalmente nos estados de Mato Grosso, Mato Grosso do Sul, Goiás, Paraná e São Paulo.

Existem outras contribuições no artigo. Além de usar dados diários, a maioria dos trabalhos usam dados semanais ou mensais, e investigar as inter-relações usando o produto soja, apenas um trabalho conhecido usou o grão, no artigo usamos uma nova metodologia desenvolvida por Herwartz e Lütkepohl (2011), pouco usada na literatura, para medir as inter-relações dos preços entre as *commodities*. O procedimento acomoda a heterocedasticidade na estimação da relação de cointegração, o que pode significar um ganho de eficiência em relação aos demais métodos. Primeiramente, analisamos a média condicional usando um modelo de correção de erros (VECM) e modelamos a volatilidade através de um modelo multivariado que permite co-movimentos de segunda ordem entre as séries (MGARCH). Todos parâmetros são estimados conjuntamente por meio de um estimador de mínimo quadrados generalizados factível (FGLS).

O restante deste artigo está estruturado da seguinte forma. A próxima seção apresentamos uma revisão da literatura sobre as transmissões de preços e os efeitos de transbordamentos entre os mercados energético e agrícola. Na seção 3 descrevemos a estratégia econométrica e na seção 4 apresentamos os resultados da análise empírica para dados reais. Por fim, concluímos na seção 6. Todas as estimações foram realizadas no software estatístico R e as séries de preços foram fornecidas pelo Centro de Estudos Avançados em Economia Aplicada (CEPEA).

2 Revisão de Literatura

Estudos sobre a transmissão da volatilidade entre os mercados de energia e agricultura ainda são escassos (SERRA, 2011; GARDEBROEK; HERNANDEZ, 2013; CABRERA; SCHULZ, 2016). A maioria dos estudos sobre inter-relações entre os biocombustíveis e os preços das *commodities* agrícolas são para Brasil e os EUA, maiores produtores de biocombustíveis. A seguir, apresentamos uma breve revisão da literatura recente sobre as transmissões de preços relacionadas aos biocombustíveis.

Balcombe e Rapsomanikis (2008) investigam ajuste não-linear para o equilíbrio de longo prazo entre petróleo bruto, etanol e açúcar no Brasil utilizando técnicas bayesianas. Encontram que os preços do petróleo determinam equilíbrio de longo prazo dos preços do açúcar e do etanol no Brasil. Também verificaram que mudanças nos preços do açúcar causaram mudanças nos preços do etanol, mas não o contrário, sugerindo uma hierarquia causal entre os mercados: do petróleo para açúcar e do açúcar para o etanol. Segundo os autores o crescimento de longo prazo esperado levará a uma expansão da demanda de energia, o que sustentará os preços do petróleo em níveis elevados e garantirá a continuidade das relações de preços entre os mercados de energia e alimentos.

Zhang et al. (2009) usa um modelo de correções vetoriais (VECM) e um modelo de heterocedasticidade condicional autorregressiva múltipla (MGARCH) para investigar as transmissões de volatilidade entre os mercados do etanol, milho, petróleo e soja nos Estados Unidos entre

o período de março de 1987 a dezembro de 2007. Como resultado, não encontra uma relação de longo prazo entre os preços das *commodities* agrícolas e dos combustíveis. Um choque nos mercados dos combustíveis pode impactar os preços das *commodities* agrícolas, porém há baixa persistência deste choque nos preços dos produtos agrícolas no curto prazo. Segundo o autor mercados descentralizados e livremente operacionais atenuarão a persistência desses choques.

Wu, Guan e Myers (2011) utilizam um modelo MGARCH para examinar o transbordamento das volatilidades entre os mercados de petróleo e milho nos Estados Unidos entre o período de janeiro de 1992 a junho de 2009. Além de encontrar evidências de transbordamento das volatilidades entre os mercados, os resultados indicam que o mercado de milho tornou-se muito mais conectado ao do petróleo após a introdução da Lei de Política Energética de 2005. Também verificam que os transbordamentos de volatilidade entre os mercados são maiores em períodos de alta taxa de consumo de gasolina-etanol.

Serra (2011) usa o método desenvolvido por Seo (2007), um estimador de máximo verossimilhança do vetor de cointegração que estima conjuntamente o ECM e processo MGARCH, para avaliar a transmissão da volatilidade de preços do etanol ao longo do tempo e entre os mercados de açúcar e petróleo. Como resultado encontra que um aumento do preço do petróleo leva à um novo equilíbrio caracterizado por preços mais altos do etanol. Também verificam que choques positivos no mercado do petróleo e do açúcar levam a um aumento da volatilidade nos preços do etanol. Em outro trabalho para o Brasil, Serra (2011) investiga as transmissões de volatilidades dos preços entre os mercados de petróleo, etanol e açúcar usando um modelo GARCH semi paramétrico e dados semanais entre período de julho de 2000 a novembro de 2010 para o Brasil. Os resultados sugerem que os preços do etanol e petróleo, tanto quanto os preços do açúcar e do etanol, estão relacionados por uma paridade de equilíbrio de longo prazo. As relações demonstram que o preço do etanol aumenta com o preço da açúcar e do petróleo. Para avaliar os efeitos de transbordamento da volatilidade a autora usou um modelo BEKK. Como resultado, obteve que choques do petróleo e no mercado de açúcar levam a uma maior volatilidade nos preços do etanol. No entanto, o mercado do etanol possui pouca capacidade de aumentar a instabilidade nos mercados de petróleo e açúcar. Por meio da comparação das variâncias simuladas sob os modelos GARCH paramétrico e semiparamétrico a autora conclui que os estimadores semiparamétricos podem captar com mais precisão o comportamento dos preços durante os períodos turbulentos.

Serra e Gil (2013) usam dados mensais de janeiro de 1990 a dezembro de 2010 para estudar a volatilidade do preço do milho nos Estados Unidos. Para tanto os autores estimam um modelo MGARCH, que permite variáveis exógenas, parametricamente e semiparametricamente. Como resultado, encontram evidências de transmissão de volatilidade entre os mercados do etanol e milho. Também verificam que estoques de milho diminuem a volatilidade dos preços deste produto, enquanto instabilidade econômica leva a um aumento da instabilidade dos preços. Os autores destacam a relevância de estender as análises de transbordamento de volatilidade entre os mercados de alimentos e energia considerando um conjunto mais amplo de variáveis explicativas, uma vez que variáveis exógenas se mostraram importantes nos modelos de volatilidade.

Gardebroek e Hernandez (2013) usam a abordagem MGARCH para examinar a transmissão de volatilidade nos preços do petróleo, etanol e milho entre os anos de 1997 e 2011 para os Estados Unidos. Particularmente, os autores estimam o modelo T-BEKK e um modelo DCC. Os resultados indicam que não existem transbordamentos cruzados para os retornos médios entre os mercados de petróleo, etanol e milho. O retorno médio observado de cada *commodity* é influenciado somente pelo retorno defasado do mesmo mercado e não pelos retornos defasados nos outros mercados. As *commodities* também apresentaram efeitos de volatilidade própria significativas e elevadas, sendo que o etanol mostrou uma mais baixa persistência da própria volatilidade. Os efeitos cruzados para volatilidade se apresentaram significativos, porém com menor magnitude do que a volatilidade própria. Para estudar as interações ao longo do tempo entre as *commodities*

os autores estimaram os modelos para subamostras. Entre os resultados, encontraram que o etanol e milho apresentaram uma maior interação nos últimos anos da amostra, período no qual o etanol tornou-se o principal substituto para a gasolina. Além disso, as estimações mostraram importantes efeitos de transbordamento do milho para o etanol e não o contrário. Os resultados não fornecem evidências que a volatilidade nos mercados de energia estimulam a volatilidade de preços no mercado do milho.

Cabrera e Schulz (2016) investigam as ligações de curto e longo prazo entre os preços de combustíveis e de *commodities* agrícolas na Alemanha no período de 2003 a 2012. No artigo as autoras usam um novo estimador de mínimos quadrados generalizados factível introduzido por Herwartz e Lütkepohl (2011), que acomoda a heterocedasticidade no procedimento de estimação da relação de cointegração. Mais precisamente é calculado VECM para filtrar os comovimentos entre as séries. As tendências de curto prazo, resíduos do VECM, são usadas para modelar as inter-relações de volatilidade através de um modelo MGARCH. Todos os parâmetros, tanto do VECM e MGARCH, são calculados conjuntamente por meio de estimador FGLS. Como resultado encontram que as volatilidades e correlações são altamente persistentes no curto prazo. Verificam que os preços se movem juntos e preservam um equilíbrio de longo prazo, onde os preços do biodiesel se ajustam aos preços do petróleo bruto e da colza. Também encontram que a volatilidade do biodiesel está apenas ligada fracamente à volatilidade do petróleo bruto e da colza tanto no curto como no longo prazo, enquanto a ligação entre a volatilidade da colza e do petróleo está aumentando nos últimos anos. Com base nestes resultados, concluem que as preocupações com o biodiesel como causa dos altos e voláteis preços dos alimentos são injustificadas.

Como podemos observar, apesar de existirem alguns trabalhos sobre as transmissões de preços e volatilidade entre os mercados de combustíveis e alimentos para o Brasil, não existem estudos sobre inter-relações do mercado de biocombustível com a *commodity* soja. O trabalho busca compreender estas inter-relações, uma vez que a cana-de-açúcar (matéria prima para etanol e açúcar) e a soja estão entre os principais produtos agrícolas produzidos no Brasil. Além disso, a grande maioria dos estudos usaram dados mensais ou semanais, sendo que este trabalho utiliza dados diários. Trabalhos com esta periodicidade não foram encontrados para o mercado de *commodities* brasileiro. Com isso questões de microestrutura do mercado de *commodities* podem ser melhor captadas, sendo que a periodicidade tende a influenciar os resultados de estudos de volatilidade e conforme Moreira e Lemgruber (2004) uma menor frequência de dados melhoram o ajuste do modelo e sua previsibilidade.

3 Metodologia

Muitas séries de preços possuem duas características importantes que devem ser consideradas em estudos estatísticos: (i) movimentos comuns entre séries de preços ao longo do tempo, (ii) preços altamente voláteis com a volatilidade variando com o tempo. Considerando estas propriedades é necessário cuidado para especificar e estimar a média e variância das séries. Desenvolvido por Herwartz e Lütkepohl (2011) e usado por Cabrera e Schulz (2016), neste trabalho usamos um estimador de mínimo quadrados generalizados factível para estimar conjuntamente a média condicional, por meio de um modelo de correção de erros, e a volatilidade, através de um modelo heterocedástico multivariado.

3.1 Modelo de Correção de Erros

Séries de preços que possuem movimentos comuns ao longo do tempo são ditas cointegradas. Engle e Granger (1987) introduziram o conceito para séries não estacionárias e integradas de mesma ordem. Posteriormente Campbell e Perron (1991) generalizaram a definição permitindo cointegração de séries com diferentes ordens. A cointegração de séries temporais indica uma relação de causalidade de longo prazo, porém não indica a direção dessa causalidade temporal

entre as séries. Tal direção de causalidade pode ser determinada com um vetor de correção de erros (VECM) que acomoda tanto a dinâmica de curto como a dinâmica de equilíbrio de longo prazo na sua estrutura. Formalmente este modelo se apresenta:

$$\Delta p_t = c + \Pi p_{t-1} + \Gamma \Delta p_{t-1} + u_t \quad (1)$$

$$\Delta p_t = c + \alpha \beta^T p_{t-1} + \Gamma \Delta p_{t-1} + u_t. \quad (2)$$

Onde Δ é um operador de primeira diferença, tal que $\Delta p_t = p_t - p_{t-1}$ denota a mudança de preços p de tempo $t - 1$ para tempo t (variações de preço de curto prazo), c é uma constante, α dá a velocidade de ajuste com a qual os preços retornam ao equilíbrio de longo prazo, Γ mede as reações a mudanças de preços de curto prazo e u_t é um termo de erro que capta potenciais efeitos da volatilidade.

3.2 Modelo GARCH Multivariado

Uma *commodity* pode sofrer de momentos de alta e baixa instabilidade de preços ao longo do tempo. Além disso, a instabilidade de preços de uma *commodity* pode levar a uma instabilidade de preços de outra *commodity*. Em outras palavras, as volatilidades de algumas séries podem estar inter-relacionadas. Para estudar estas relações e possíveis transmissões de volatilidade entre as séries ao longo do tempo usamos um modelo GARCH multivariado. Denota-se um vetor n -variado de T observações, no qual $E(u_t|F_{t-1})$ é gerado pelo passado até F_{t-1} . Assume-se que u_t é um vetor dos resíduos do VECM. O modelo GARCH multivariado é definido como:

$$u_t = H_t^{1/2} z_t, \quad z_t \sim iid(0, I_n), \quad t = 1, 2, \dots, T, \quad (3)$$

onde H_t é uma matriz positiva definida tal que $H_t^{1/2}(H_t^{1/2})^T = H_t$ e $H_t = Var(u_t|F_{t-1})$ é a matriz de covariância de u_t sobre o conjunto de informações F_{t-1} . A variância não condicional é assumida constante ao longo do tempo. Muitas especificações da matriz de covariância condicional são propostas na literatura. [Cabrera e Schulz \(2016\)](#) utilizaram o modelo de correlação condicional constante (CCC) e o modelo de correlação condicional dinâmica (DCC). Os modelos produzem resultados facilmente interpretáveis e mantêm o número de parâmetros a ser estimado relativamente baixo. O interessante de modelos de correlação condicional é que a matriz H_t pode ser decomposta em variâncias condicionais e uma matriz de correlação condicional, no qual pode ser especificada separadamente. O modelo pode ser definido como:

$$H_t = D_t R_t D_t \quad (4)$$

$$D_t = diag(h_{11t}^{1/2}, \dots, h_{nnt}^{1/2}) \quad (5)$$

$$R_t = (I_n \odot Q_t)^{-1/2} Q_t (I_n \odot Q_t)^{-1/2} \quad (6)$$

$$Q_t = (1 - a - b)\bar{Q} + a\xi_{t-1}\xi_{t-1}^T + bQ_{t-1} \quad (7)$$

Em que \odot denota o produto de Hadamard, $\xi_{it} = \frac{u_{it}}{\sqrt{h_{it}}}$ são os resíduos u_t padronizados por seus desvios padrões condicionais, \bar{Q} é a matriz de covariância incondicional de ξ_t e a e b são parâmetros escalares não-negativos que satisfazem $a + b < 1$. D_t é matriz diagonal variante no tempo dos desvios padrões dos processos GARCH univariados. O modelo de correlação

condicional constante é um caso especial do modelo DCC, onde as matrizes D e R são constantes. O modelo de correlação condicional dinâmica pode ser realizado em duas etapas. Primeiramente as variâncias condicionais são estimadas usando-se uma especificação GARCH univariada. Na segunda etapa, os resíduos padronizados são usados para estimar os parâmetros das correlações dinâmicas. Assumindo que z_t em (3) seja normalmente distribuído, é possível obter estimativas consistentes por meio de estimador de quasi-máxima verossimilhança em dois estágios.

3.3 Estimação Conjunta dos Parâmetros de Cointegração e GARCH

A abordagem mais conhecido para estimar parâmetros de cointegração é a que foi desenvolvido por [Johansen \(1996\)](#). No entanto, este procedimento é ineficiente na presença de heterocedasticidade condicional generalizada, como mostrado por [Seo \(2007\)](#). Para superar a problema [Seo \(2007\)](#) propôs um procedimento de máxima verossimilhança que leva em consideração a estrutura GARCH para os resíduos. Porém este procedimento sofre grande sensibilidade quando ocorre má especificação do processo GARCH e, além disso, possui fracas propriedades em pequenas amostras. O estimador de Mínimos Quadrados Generalizados Factível proposto por [Herwartz e Lütkepohl \(2011\)](#) aborda todos esses inconvenientes. Como em [Cabrera e Schulz \(2016\)](#) adotamos a última abordagem. Esta consiste em duas etapas: (i) estima-se um VECM por Mínimos Quadrados Ordinários e se salva os resíduos para, posteriormente, utilizar na estimação do MGARCH por Máximo Verossimilhança; (ii) as estimativas de Mínimos Quadrados Generalizados Factível são derivadas usando a matriz de covariância estimada a partir da primeira etapa.

3.4 Modelo Multivariado de Volatilidade Multiplicativa

A hipótese central dos modelos de MGARCH é que a matriz de covariância incondicional é constante ao longo do tempo. Porém, mudanças no ambiente de mercado podem fazer com que a matriz de covariância incondicional mude ao longo do tempo. Para permitir tais mudanças, como em [Cabrera e Schulz \(2016\)](#) e [Serra \(2015\)](#), usamos um modelo de volatilidade multiplicativo desenvolvido por [Hafner e Linton \(2010\)](#), que permite mudanças suaves na matriz de covariância incondicional através de uma componente multiplicativo. A ideia do modelo de volatilidade multiplicativa é decompor a matriz de covariância condicional de u_t em um componente que pode mudar suavemente ao longo do tempo (componente de longo prazo) e um componente de curto prazo que captura variações em torno do nível que varia levemente. O componente de longo prazo é modelado como uma função suave em relação ao tempo e corresponde à covariância incondicional. O componente de curto prazo captura a dinâmica potencial de processos GARCH multivariados. Segue o modelo:

$$H_t = \sum (t/T)^{1/2} G_t^{1/2} (G_t^{1/2})^T \left[\sum (t/T)^{1/2} \right]^T = \sum (t/T)^{1/2} G_t \left[\sum (t/T)^{1/2} \right]^T. \quad (8)$$

Ao assumir $E(G_t) = I_n$ para identificação, segue-se que

$$Var(u_t) = E(H_t) = \sum (t/T)^{1/2} E(G_t) \left[\sum (t/T)^{1/2} \right]^T = \sum (t/T), \quad (9)$$

onde $\sum (t/T) = \sum t$ é matriz de covariância não condicional de u_t . Deixe $\varepsilon = \sum (t/T)^{-1/2} u_t$ o vetor de resíduos padronizado por sua covariância incondicional. Segue-se que $Var(\varepsilon_t) = I_n$ e $Var(\varepsilon_t | F_{t-1}) = G_t$. Portanto, ε_t é um vetor com uma matriz de covariância incondicional constante e com G_t como sua matriz de covariância condicional. No caso dos resíduos padronizados ε_t mostrarem efeitos ARCH, eles podem ser modelados usando um modelo GARCH multivariável como descrito anteriormente. Devido à padronização, eles seguem uma hipótese de uma matriz

de covariância incondicional constante. De acordo com Hafner e Linton (2010), a matriz de covariância incondicional $\sum(t/T)$ pode ser estimada eficientemente pelo Nadaraya-Watson não paramétrico:

$$\hat{\sum}(\tau) = \frac{\sum_{t=1}^T K_h(\tau - \frac{t}{T}) u_t u_t^T}{\sum_{t=1}^T K_h(\tau - \frac{t}{T})}, \quad (10)$$

o $\tau = \frac{1}{T}, \frac{2}{T}, \dots, 1$, $K_h(\cdot)$ é uma função do kernel e h é um parâmetro de suavização positivo que separa o componente de longo e curto prazo da matriz de covariância. Para escolher o parâmetro de suavização utiliza-se um critério de validação cruzada de verossimilhança como proposto por (Yin et al., 2010):

$$CV(h) = \frac{1}{n} \sum_{t=1}^T [u_t^T \sum_{(-t)}^{-1} (t/T) u_t] + \log[|\sum_{(-t)}^{-1} (t/T)|], \quad (11)$$

onde \sum_{-t} é o estimador matriz de covariância incondicional. Ou seja, a Eq. (10) é estimada com a t -ésima observação deixada de fora. O parâmetro de suavização ótimo é determinado minimizando a Eq. (11) e por simplicidade um kernel gaussiano é escolhido.

4 Dados e Análise Descritiva.

Os dados são de periodicidade diária, são disponibilizados pela [CEPEA/EXALQ](#) e se referem ao período de 25/01/2010 a 20/01/2017, porém ao se deflacionarem os dados a série foi reduzida para 29/12/2016 pois não foram encontrados o índice de preço para o no de 2017. Os dados para o etanol correspondem ao Indicador Diário do Etanol Hidratado ESALQ/BM&FBovespa Posto Paulínia (SP). Para o açúcar os dados são o Indicador Açúcar Criatal CEPEA/EXALQ - São Paulo por saca de 50 quilos. Para o soja os dados são o Indicador Soja CEPEA/EXALQ - Paraná por saca de 60 quilos. Ocorreram 15 valores faltante para o soja durante o período, estes dados foram interpolados pelo método *spline* conforme indicado por [Zeileis e Grothendieck \(2005\)](#).

Tabela 1 – Resumo das séries de preços

acucar	etanol	soja	Data
Min. :32.97	Min. : 732.5	Min. : 39.99	Min. :2010-01-25
1st Qu.:48.25	1st Qu.:1105.1	1st Qu.: 49.13	1st Qu.:2011-10-20
Median :63.17	Median :1190.5	Median : 53.92	Median :2013-07-24
Mean :61.47	Mean :1238.0	Mean : 59.97	Mean :2013-07-23
3rd Qu.:73.06	3rd Qu.:1317.0	3rd Qu.: 71.58	3rd Qu.:2015-04-23
Max. :93.18	Max. :1924.5	Max. :100.92	Max. :2017-01-20

Para vizualização dos dados foi plotado na [Figura 1](#) os gráficos do logarítmo da série de preços e do logarítmo da série de preços deflacionada. Os dados foram deflacionados pelo Índice de Preço ao Produtor (IPP). Optou-se pela apresentação na forma de logaritmo devido a diferença de escala entre o preço do etanol e dos preços da soja e açúcar, além de que, conforme [Tsay \(2012\)](#) as variáveis em logaritmo quando diferenciadas nos dão uma aproximação da taxa de crescimento, ou no caso do mercado financeiro, do retorno do ativo. A Figura 2 mostra a volatilidade medida por v_i^2 do etanol, açúcar e soja, sendo $v_{i,t}$ uma medida classificada na literatura de finanças como retorno do ativo e em outros trabalhos como uma outra medida de

volatilidade, sendo que:

$$v_{i,t} = \Delta \log p_{i,t}. \quad (12)$$

Em que $p_{i,t}$ é o preço da *commodity* i , t é o período (dia, neste caso) e $i = \text{commodity}$ de interesse. Percebe-se que a volatilidade do preço do açúcar é bem mais intensa e com maior amplitude se comparadas às volatilidades do preço do soja e do preço do etanol. Entretanto, conforme [Cabrera e Schulz \(2016\)](#) é característico das séries de preços de *commodities* serem cointegradas e uma medida de volatilidade que leve em conta esta característica dos dados se torna mais apropriada. Para isso pode-se modelar a média da série de preços por meio de um modelo de correção de erros (VECM, sigla em inglês) e então filtrar a série de preços do co-movimento de suas médias condicionais. A partir de então podem ser obtidas medidas de volatilidade livres da influência deste co-movimento entre as médias condicionais de preços.




Figura 1 – Logarítmo dos preços diários e preço diário deflacionado pelo Índice de Preço do Produtor (IPP) para o etanol, açúcar e soja




Figura 2 – Volatilidade medida pela diferença do logarítmo do preço ao quadrado para a etanol, açúcar e soja

Tabela 2 – Distribuição das variáveis.

	Etanol	Açúcar	Soja
Média	938,48	46,35	45,82
Desvio Padrão	126,37	6,82	10,64
Correlação	1,00	-0,22	0,60
		1,00	-0,41
			1,00
Assimetria	-0,29	-0,16	-0,06
Curtose	12,33	4,29	12,85
$Q(20)$	<0,01	<0,01	<0,01
$Q^2(20)$	<0,01	<0,01	<0,01
Arch	<0,01	<0,01	<0,01
Shapiro-Wilk	<0,01	<0,01	<0,01

Na Tabela 2 são apresentados a média, desvio padrão e correlações do nível de preços do etanol, açúcar e soja. O preço do açúcar é positivamente correlacionado com o preço do etanol, o que era de se esperar pois os dois produtos são substitutos na perspectiva do produtor. Por exemplo, caso o preço do etanol esteja elevado e apresente maior lucratividade em relação ao açúcar, o produtor tende a aumentar a oferta de etanol e reduzir a oferta de açúcar, o que por sua vez, aumenta o preço do açúcar. A correlação entre soja e etanol é positiva. Esta tendência explica os co-movimentos dos preços das *commodities* no mercado financeiro internacional. Quanto à correlação negativa entre o soja e o açúcar, a análise é mais indireta em que tal correlação pode ocorrer devido a características especulativas inerentes do mercado financeiro.

As outras estatísticas da Tabela 2 se referem à volatilidade, $v_{i,t}$. As três séries apresentam assimetria à esquerda em sua distribuição. As volatilidades de soja e etanol apresentam elevado grau de leptocurtose (12,33 e 12,85) enquanto o nível de leptocurtose do açúcar (4,29) é bem inferior às outras duas *commodities*. Para os testes foram reportados o valor-p. $Q(20)$ e $Q^2(20)$ são os testes de Ljung-Box para $v_{i,t}$ e $v_{i,t}^2$ respectivamente com 20 defasagens em ambos os testes, para mais detalhes sobre o teste consulte [McLeod e Li \(1983\)](#). O teste Q possui hipótese nula de ausência de autocorrelação:

$$H_0 : \rho_1 = \rho_2 = \dots = \rho_m = 0 \quad (13)$$

contra a hipótese alternativa de que pelo menos um coeficiente de autocorrelação é diferente de zero:

$$H_a : \exists \rho_i \neq 0, \quad i = 1, \dots, m \quad (14)$$

Conforme [Tsay \(2012\)](#), a regra de decisão é rejeitar a hipótese nula caso o valor-p seja inferior ao nível de significância desejado. Os testes tanto para a v_{it} quanto para v_{it}^2 possuem valor-p inferiores a 1% o que nos leva a rejeitar a hipótese nula de ausência de autocorrelação para as três séries e, com isso, as volatilidades não são independentemente distribuídas. Arch é o teste de efeitos ARCH de Engle (1982) que é um teste de multiplicador de Lagrange para heterocedasticidade condicional. Este teste é equivalente à estatística F para testarmos se $\alpha_i = 0$, $i = 1, \dots, m$, na regressão linear

$$a_t^2 = \alpha_0 + \alpha_1 a_{t-1}^2 + \dots + \alpha_m a_{t-m}^2 + \varepsilon_t, \quad t = m + 1, \dots, T. \quad (15)$$

Em que $a_t = v_t - \mu_t$, ou seja, o resíduo em relação à média condicional, ε_t é o termo de erro, m é o número de defasagens incluídas no teste e T o tamanho da amostra. A série ao quadrado a_t^2 é usada para checar a heterocedasticidade condicional, cujo teste possui a hipótese nula

$$H_0 : \alpha_1 = \dots = \alpha_m = 0, \quad (16)$$

contra a hipótese alternativa

$$H_a : \exists \alpha_i \neq 0, \quad i = 1, \dots, m. \quad (17)$$

Maiores detalhes sobre o cálculo destas estatísticas também podem ser encontrados em [Tsay \(2012\)](#). A regra de decisão é rejeitar a hipótese nula se o valor-p for menor que o nível de significância desejado. Portanto, no teste de efeito ARCH rejeitou-se a hipótese nula de ausência de heterocedasticidade condicional para as três séries a um nível de significância de 1%. Com isso inferimos que existe heterocedasticidade condicional nas séries estudadas.

Para testar a normalidade dos dados realizou-se o teste Shapiro-Wilk, inicialmente desenvolvido por [Shapiro e Wilk \(1965\)](#). Este teste infere se a amostra estudada veio de uma distribuição normal. Como os valores-p reportados na Tabela 2 são menores que o nível de significância de 1%, rejeita-se a hipótese nula de que os dados foram amostrados de uma distribuição normal. Até então todos as estatísticas estão em conformidade com a literatura de volatilidade no mercado financeiro, em que os dados apresentam leptocurtose, assimetria à esquerda, heterocedasticidade condicional e não normalidade em sua distribuição. Alguns trabalhos recentes que identificaram estas características são, [Cabrera e Schulz \(2016\)](#), [Freitas et al. \(2015\)](#) e [Araujo e Montini \(2015\)](#), para uma excelente revisão sobre o assunto, veja [Serra e Zilberman \(2013\)](#).

4.1 Testes de estacionariedade, raiz unitária e cointegração.

Em seguida foram feitos os testes Dickey-Fuller aumentado (ADF, sigla em inglês), KPSS e Phillips-Perron para identificar se as séries de preços possuem raiz unitária, no caso dos testes ADF e Phillips-Perron ou se as séries de preços são estacionárias, por meio do teste KPSS. A Tabela 3 mostra as estatísticas do teste KPSS e o valor tabelado por nível de significância. Podemos ver nesta tabela que todas as estatísticas, independente da especificação do modelo, são maiores que os valores tabelados, portanto não rejeitamos a hipótese nula de estacionariedade. As tabelas 4 e 6 mostram os testes ADF e Phillips-Perron respectivamente. A diferença destes dois testes em relação ao teste KPSS, é que eles possuem hipótese nula de existência de raiz unitária. Conforme as duas tabelas 4 e 6, para qualquer especificação do modelo não rejeitamos a hipótese nula de existência de raiz unitária nas séries estudadas. Uma vez que evidenciamos a existência de raiz unitária nas séries de preços, foram realizados os mesmos testes para as séries em primeira diferença, onde constatou-se que elas são integradas em primeira ordem. A partir disso podemos prosseguir para a identificação de cointegração e estimação do modelo de vetor de correção de erros (VECM, sigla em inglês).

Tabela 3 – Teste KPSS preço em nível

	etanol	acucar	soja	1 Pct	2.5 Pct	5 Pct	10 Pct
Time Trend:	1.57	3.80	5.17	0.22	0.18	0.15	0.12
No Trend:	1.88	10.65	9.45	0.74	0.57	0.46	0.35

Tabela 4 – Teste ADF preço em nível

	etanol	acucar	soja	1 Pct	2.5 Pct	5 Pct	10 Pct
Time Trend:	-3.83	-1.67	-2.44	-3.96	-3.66	-3.41	-3.12
Constant:	-3.87	-1.90	-2.67	-3.43	-3.12	-2.86	-2.57
Neither:	-0.16	0.27	-0.39	-2.58	-2.23	-1.95	-1.62

Tabela 5 – Defasagens do teste ADF

	Trend Model	Drift Model	None
etanol	2	2	2
acucar	1	1	1
soja	6	6	5

Tabela 6 – Teste Phillips-Perron

	Z(α)	Defasagem	valor-p
Etanol	-18,99	8	0,09
Açúcar	-6,74	8	0,07
Soja	-3,90	8	0,90

Como critério para seleção da ordem de defasagem do modelo VAR usamos os critérios AIC, BIC e HQ. Estes testes reportaram como número de defasagens ótimas, 7, 4 e 6, respectivamente e por uma questão de parcimônia usamos o número de defasagens sugerido pelo critério BIC (4 defasagens). Como o número ótimo de defasagens do modelo VAR é 4, para o teste de cointegração devemos usar 3 defasagens. O teste realizado foi o teste do traço de Johansen que possui hipótese nula de ausência de cointegração contra uma hipótese alternativa de cointegração entre as variáveis. O teste do traço verifica se o posto (*rank*) da matriz de cointegração $\Pi = \alpha\beta'$ é igual a zero. A hipótese alternativa é a de que $0 < \text{rank}(\Pi) < n$ e n é o número máximo possível de vetores de cointegração. Se a hipótese nula de que o posto da matriz Π seja zero for rejeitada, realiza-se o teste novamente com a hipótese nula de que o posto seja 1 e assim sucessivamente até não se rejeitar a hipótese nula. O posto da matriz Π será definido logo quando não se rejeitar a hipótese nula do teste. O número de vetores de cointegração é igual ao posto da matriz Π .

Tabela 7 – Teste do traço de Johansen

H_0	H_a	Estatística do teste	Valor crítico a 5%
$r = 0$	$r > 0$	42,16	31,52
$r \leq 1$	$r > 1$	13,22	17,95
$r \leq 2$	$r > 2$	4,12	8,18

Como se verifica na Tabela 7, inicialmente rejeitou-se a hipótese nula de que o posto da matriz Π seja zero, em seguida não se rejeitou a hipótese nula de que o posto seja igual a um. Logo, existe uma única relação de cointegração dada por:

$$p_t^e - 0,03 p_t^a - 0,316 p_t^s = 0 \quad (18)$$

em que p_t^e , p_t^a e p_t^s são os preços do etanol, açúcar e soja, respectivamente. Agora, dado

o vetor de cointegração, podemos estimar o modelo VECM para obtermos a volatilidade livre do co-movimento entre as médias dos preços.

4.2 Estimação do modelo de vetor de correção de erros.

Foi estimado um modelo de vetor de correção de erros a partir do vetor de cointegração encontrado anteriormente. Tanto a relação de longo prazo, quanto a dinâmica de curto prazo são capturadas por este modelo. Depois de realizado um refinamento ao remover os coeficientes não significantes a 5% o modelo parcimonioso ficou (erro padrão entre parênteses):

$$\begin{aligned}\Delta p_t^e &= -0,01 \underset{(0,002)}{\hat{\beta}^T p_{t-1}} + 0,373 \underset{(0,024)}{\Delta p_{t-1}^e} + 0,258 \underset{(0,024)}{\Delta p_{t-2}^e} + 0,061 \underset{(0,015)}{\Delta p_{t-2}^s} + 0,036 \underset{(0,024)}{\Delta p_{t-3}^e} + u_t, \\ \Delta p_t^a &= -0,005 \underset{(0,002)}{\hat{\beta}^T p_{t-1}} - 0,057 \underset{(0,021)}{\Delta p_{t-1}^e} + 0,2 \underset{(0,023)}{\Delta p_{t-1}^a} - 0,026 \underset{(0,017)}{\Delta p_{t-2}^s} - 0,043 \underset{(0,022)}{\Delta p_{t-3}^e} + u_t, \\ \Delta p_t^s &= 0,22 \underset{(0,023)}{\Delta p_{t-1}^s} + 0,174 \underset{(0,024)}{\Delta p_{t-2}^s} + 0,23 \underset{(0,023)}{\Delta p_{t-3}^s} + u_t.\end{aligned}\quad (19)$$

em que $\hat{\beta}^T p_{t-1}$ é a relação de cointegração estimada na equação (18). Dado que os preços são diários o conjunto de equações em (19) representam as mudanças percentuais de um dia para o outro. Com relação ao etanol, a relação de longo prazo entre as variáveis impacta negativamente o retorno do ativo (Δp_t^e). O retorno do etanol sofre impacto de seus componentes autorregressivos e do retorno do soja na defasagem de segunda ordem, porém o efeito da soja é fraco se comparado com os componentes autorregressivos.

O retorno do açúcar também sofre impacto negativo dos co-movimento entre as médias dos preços, assim como o retorno do etanol. Já seus componentes autorregressivos impactam seu retorno de forma positiva, já que o efeito autorregressivo de primeira ordem sobrepõe o efeito de terceira ordem. O etanol impacta o retorno do açúcar de forma negativa, fato que corrobora a relação direta de oferta entre os dois produtos. Para o açúcar, destaca-se ainda um efeito significativo do soja no termo de segunda defasagem, porém, como para o etanol, o efeito é muito fraco e dissipado pelos componentes autorregressivos. Por fim o retorno da soja também possui forte impacto positivo de seus componentes autorregressivos e não apresenta nenhuma influência significativa dos demais retornos.

Na figura 3 estão plotados os resíduos do modelo VECM estimado com refinamento. Visualmente fica perceptível a heterocedasticidade condicional dos termos de erro, porém alguns teste estatísticos para detectar a heterocedasticidade condicional ainda são necessários. Os testes escolhidos foram os testes de Portmanteau e os teste baseados no posto.




Figura 3 – Resíduos das estimação do modelo de vetor de correção de erros (VECM)

Como consta na Tabela 8 os três primeiros testes se referem ao teste de Portmanteau ($Q_k^*(m)$) e suas extensões, a versão ajustada para a média ($Q^*(m)$), a versão robusta com

truncamento de cauda superior de 5% ($Q_k^r(m)$) e o teste de posto ($Q_R(m)$). Para mais detalhes sobre estes testes [Tsay \(2013\)](#) fornece um excelente ponto de partida.

Tabela 8 – Testes de heterocedasticidade condicional.

	$Q_k^*(m)$	$Q^*(m)$	$Q_k^r(m)$	$Q_R(m)$
Teste	646,09	213,39	503,87	184,77
valor-p	<0,01	<0,01	<0,01	<0,01

Todos os teste falharam em rejeitar a hipótese nula de ausência de heterocedasticidade condicional a um nível de significância inferior a 1%, como era o esperado já que observamos na Figura 3 que os dados sugeriam a ocorrência de heterocedasticidade condicional e os dados por se tratarem de séries financeiras geralmente possuem este comportamento. Uma vez que foi identificada a heterocedasticidade condicional para a série de dados podemos modelar a heterocedasticidade condicional.

4.3 Estimação do modelo BEKK.

Na seção anterior realizou-se a estimação do modelo de vetor de correção de erros para a obtenção do resíduo livre do co-movimento entre as médias. Porém, ao usarmos 4 defasagens para o modelo VAR, e conseqüentemente 3 defasagens para o modelo VEC, os resíduos do modelo VEC ainda apresentaram correlação. Já que o método de estimação BEKK proposto por [Engle e Kroner \(1995\)](#) supõe que os dados sejam não correlacionados e isso não ocorreu após a estimação do modelo VEC (os resíduos permaneceram correlacionados) foi realizado o mesmo procedimento anterior, mas escolhendo diferentes defasagens para o modelo VAR. Constatamos que usando o número máximo de defasagens (7), indicado pelo critério AIC, os resíduos do modelo VEC estimado posteriormente não apresentam correlação serial até a vigésima defasagem. Portanto o modelo BEKK será estimado usando os resíduos do modelo VEC com 6 defasagens.

Com este novo número de defasagens escolhido, assim como no caso anterior, identificamos um único vetor de cointegração (1, -0,125, -0,358). Para sintetizar as correlações dos resíduos do modelo VEC(7), plotamos os valores-p do teste de Ljung-BOx realizado para estes resíduos.

Como podemos observar, todas os valores-p são maiores que 5% (linha tracejada). Portanto para estas defasagens não se rejeita a hipótese nula de ausência de autocorrelação e correlação entre as variáveis. Uma vez identificado que os resíduos não são correlacionados, como impõe o modelo BEKK, podemos seguir adiante nas estimações.

```
## Initial estimates:  -3.370388e-06 9.138433e-05 -2.972673e-05 0.008118471 0.0004654883
## Lower limits:  -3.370388e-05 -0.0009138433 -0.0002972673 0.001623694 9.309765e-05 0.00
## Upper limits:  3.370388e-05 0.0009138433 0.0002972673 0.008930318 0.0005120371 0.00060
##
## Coefficient(s):
##           Estimate      Std. Error  t value  Pr(>|t|)
## mu1.etanol -2.84925e-06  2.47352e-04 -0.01152  0.9908093
## mu2.acucar  9.14653e-05  3.29909e-04  0.27724  0.7815925
## mu3.soja   -3.01570e-05  2.05733e-04 -0.14658  0.8834611
## A011       7.18811e-03           NA         NA         NA
## A021       4.24346e-04  3.56933e-04  1.18887  0.2344910
## A031       4.97986e-04  1.92549e-04  2.58629  0.0097017 **
## A022       8.14837e-03           NA         NA         NA
## A032       7.05890e-04           NA         NA         NA
## A033       4.89427e-03           NA         NA         NA
```




Figura 4 – Plotagem dos valores-p das defasagens do teste multivariado de correlação Ljung-Box.

```
## A11      9.99998e-02  4.68451e-02  2.13469  0.0327862 *
## A21      1.99998e-02  3.27585e-02  0.61052  0.5415152
## A31      1.99996e-02  2.29792e-02  0.87034  0.3841162
## A12      1.99997e-02  2.67969e-02  0.74634  0.4554604
## A22      9.99993e-02  3.03239e-02  3.29770  0.0009748 ***
## A32      1.99997e-02  1.91742e-02  1.04305  0.2969232
## A13      1.99998e-02  3.69084e-02  0.54188  0.5879025
## A23      1.99999e-02  4.11480e-02  0.48605  0.6269333
## A33      9.99995e-02  3.83827e-02  2.60533  0.0091786 **
## B11      7.99983e-01  8.83433e-03  90.55387 < 2.22e-16 ***
## B21      1.99973e-02  1.39432e-02  1.43420  0.1515161
## B31      1.99956e-02  5.13848e-03  3.89134  9.9692e-05 ***
## B12      1.99964e-02  1.19954e-02  1.66700  0.0955135 .
## B22      7.99983e-01      NA      NA      NA
## B32      1.99949e-02  3.52939e-03  5.66526  1.4680e-08 ***
## B13      1.99974e-02  1.26003e-02  1.58705  0.1125005
## B23      1.99977e-02  1.28828e-02  1.55228  0.1205947
## B33      7.99982e-01      NA      NA      NA
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Todos os coeficientes foram positivos, o que era esperado pois o modelo BEKK implica que a matriz de variância e covariância seja positiva definida. Poucos coeficientes estimados se mostraram significantes, o que significa dizer que as volatilidades passadas não têm grande impacto sobre sua própria volatilidade corrente e sobre as volatilidades dos preços das outras

commodities. Os efeitos que se mostraram significativos com nível de significância de 5% foram: Com respeito ao impacto médio da volatilidade (matriz de covariância incondicional) apenas a soja é impactada pelo etanol, os demais efeitos não são significativos. Em relação aos efeitos ARCH, as três *commodities* apresentaram sofrer influência de suas próprias inovações e nenhum efeito cruzado se mostrou significativo. Agora com respeito ao componente autorregressivo da matriz da covariâncias (efeito GARCH), somente o etanol se mostrou significativo com respeito à efeitos próprios. Os efeitos cruzados GARCH ocorreram para o soja sendo impactado tanto pelo etanol quanto pelo açúcar. Ao que sugere o modelo BEKK estimado, somente o soja sofre impactos significativos das outras *commodities*, enquanto o açúcar e o etanol sofrem influência apenas de suas próprias inovações e volatilidades defasadas. Outra conclusão que se pode tirar do modelo, é que o etanol possui um efeito mais forte sobre o soja do que o açúcar, pois o etanol afeta o soja por meio da matriz de covariância condicional e incondicional, enquanto o açúcar impacta o soja apenas pela matriz de covariância condicional.

5 Conclusão e Comentários Finais

Neste artigo avaliamos os transbordamentos de volatilidade entre o mercado do etanol e de commodities agrícolas no Brasil utilizando o Modelo Multivariado GARCH Baba–Engle–Kraft–Kroner (BEKK). São usados dados diários de janeiro de 2010 a dezembro de 2016 para commodities soja, etanol e açúcar. Inicialmente foi estimado um modelo de vetor de correção de erros para filtrar as séries de sua relação de longo prazo e depois modelar suas respectivas volatilidades sem a interferência do co-movimento entre as médias dos preços.

Os resultados sugerem que os preços do etanol, soja e açúcar estão relacionados por dinâmica de equilíbrio de longo prazo. Além disso, a soja é impactada pelo preço do etanol, enquanto o contrário não é válido. Este resultado pode ser explicado pelo disputa de terras entre as culturas de cana-de-açúcar e de soja. Para a volatilidade obtemos que somente o soja sofre impactos significativos das outras commodities, enquanto o açúcar e o etanol sofrem influência apenas de suas próprias inovações e volatilidades. Também verificamos que o etanol possui um efeito mais forte sobre o soja do que o açúcar, pois o etanol afeta o soja por meio da matriz de covariância condicional e incondicional (efeitos de longo prazo e curto prazo), enquanto o açúcar impacta o soja apenas pela matriz de covariâncias condicional (efeito de curto prazo).

Nossos resultados têm implicações políticas importantes. Diferentemente de [Serra \(2011\)](#) e [Cabrera e Schulz \(2016\)](#) e como [Gardebroeck e Hernandez \(2013\)](#) encontramos evidências significativas de transbordamento de volatilidades do mercado do etanol para os mercados de alimentos (soja). Isso é consistente ao fato que as culturas de cana de açúcar e soja concorrem com mesmo espaço territorial no Brasil. Conclui-se que a preocupação do etanol como causa da instabilidade dos preços dos alimentos pode ser justificada pelos resultados encontrados.

Para pesquisas futuras pretendemos usar o modelo [Herwartz e Lütkepohl \(2011\)](#) para medir as inter-relações dos preços entre as commodities. O procedimento acomoda a heterocedasticidade na estimação da relação de cointegração, o que pode levar a um ganho de eficiência nas estimações.

Como comentários finais, apesar de ter apresentado o artigo, não conseguimos realizar as estimações pelo modelo proposto por [Herwartz e Lütkepohl \(2011\)](#), então utilizamos o modelo VECM tradicional que não controla para a heterocedasticidade das séries. Outro modelo a ser testado é o modelo de Dinâmico de Correlação Cruzada (DCC), que seria o recíproco do modelo BEKK. O modelo BEKK sofre com o problema de dimensionalidade, sendo que estima muitos parâmetros, e um modelo com mais de três variáveis se torna complexo ([TSAY, 2013](#)). Entretanto, o modelo DCC supõe que variáveis diferentes causem o mesmo efeito nas volatilidades, o que reduz consideravelmente o número de parâmetros a ser estimados, mas empiricamente este modelo tende a não apresentar resultados significativos ([TSAY, 2013](#)).

Referências

- ARAUJO, A. C. d.; MONTINI, A. d. v. Estimação da volatilidade percebida futura por meio de combinação de projeções. *Anais*, 2015. Disponível em: <http://bdpi.usp.br/single.php?_id=002723087>. Citado na página 10.
- BALCOMBE, K.; RAPSOMANIKIS, G. Bayesian Estimation and Selection of Nonlinear Vector Error Correction Models: The Case of the Sugar-Ethanol-Oil Nexus in Brazil. *American Journal of Agricultural Economics*, v. 90, n. 3, p. 658–668, ago. 2008. ISSN 0002-9092. Disponível em: <<https://academic.oup.com/ajae/article/90/3/658/61542/Bayesian-Estimation-and-Selection-of-Nonlinear>>. Citado na página 2.
- BYRNE, J. P.; FAZIO, G.; FIESS, N. Primary commodity prices: Co-movements, common factors and fundamentals. *Journal of Development Economics*, v. 101, p. 16–26, mar. 2013. ISSN 0304-3878. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0304387812000752>>. Citado na página 1.
- CABRERA, B. L.; SCHULZ, F. Volatility linkages between energy and agricultural commodity prices. *Energy Economics*, v. 54, p. 190–203, fev. 2016. ISSN 0140-9883. Disponível em: <<http://www.sciencedirect.com/science/article/pii/S0140988315003400>>. Citado 8 vezes nas páginas 1, 2, 4, 5, 6, 8, 10 e 15.
- CAMPBELL, J. Y.; PERRON, P. Pitfalls and Opportunities: What Macroeconomists Should Know about Unit Roots. *NBER Macroeconomics Annual*, v. 6, p. 141–201, 1991. ISSN 0889-3365. Disponível em: <<http://www.jstor.org/stable/3585053>>. Citado na página 4.
- ENGLE, R. F.; GRANGER, C. W. J. Co-Integration and Error Correction: Representation, Estimation, and Testing. *Econometrica*, v. 55, n. 2, p. 251–276, 1987. ISSN 0012-9682. Disponível em: <<http://www.jstor.org/stable/1913236>>. Citado na página 4.
- ENGLE, R. F.; KRONER, K. F. Multivariate Simultaneous Generalized Arch. *Econometric Theory*, v. 11, n. 1, p. 122–150, 1995. ISSN 0266-4666. Disponível em: <<http://www.jstor.org/stable/3532933>>. Citado na página 13.
- FREITAS, C. A. d. et al. Volatilidade dos Retornos de Commodities Agropecuárias Brasileiras: um teste utilizando o modelo APARCH. *Revista de Economia e Sociologia Rural*, v. 53, n. 2, p. 211–228, jun. 2015. ISSN 0103-2003. Disponível em: <http://www.scielo.br/scielo.php?script=sci_abstract&pid=S0103-20032015000200211&lng=en&nrm=iso&tlng=pt>. Citado na página 10.
- GARDEBROEK, C.; HERNANDEZ, M. A. Do energy prices stimulate food price volatility? Examining volatility transmission between US oil, ethanol and corn markets. *Energy Economics*, v. 40, p. 119–129, nov. 2013. ISSN 0140-9883. Disponível em: <<http://www.sciencedirect.com/science/article/pii/S0140988313001266>>. Citado 4 vezes nas páginas 1, 2, 3 e 15.
- GORTER, H. de; JUST, D. *The Welfare Economics of an Excise-Tax Exemption for Biofuels*. [S.l.], 2007. Disponível em: <<http://econpapers.repec.org/paper/pramprapa/5151.htm>>. Citado na página 2.
- HAFNER, C. M.; LINTON, O. Efficient estimation of a multivariate multiplicative volatility model. *Journal of Econometrics*, v. 159, n. 1, p. 55–73, nov. 2010. ISSN 0304-4076. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0304407610001132>>. Citado na página 6.

HERWARTZ, H.; LÜTKEPOHL, H. Generalized least squares estimation for cointegration parameters under conditional heteroskedasticity. *Journal of Time Series Analysis*, v. 32, n. 3, p. 281–291, maio 2011. ISSN 1467-9892. Disponível em: <<http://onlinelibrary.wiley.com/doi/10.1111/j.1467-9892.2010.00698.x/abstract>>. Citado 4 vezes nas páginas 2, 4, 6 e 15.

JOHANSEN, S. *Likelihood-based Inference in Cointegrated Vector Autoregressive Models*. [S.l.]: Oxford University Press, 1996. ISBN 978-0-19-877450-1. Citado na página 6.

MCLEOD, A. I.; LI, W. K. Diagnostic Checking Arma Time Series Models Using Squared-Residual Autocorrelations. *Journal of Time Series Analysis*, v. 4, n. 4, p. 269–273, jul. 1983. ISSN 1467-9892. Disponível em: <<http://onlinelibrary.wiley.com/doi/10.1111/j.1467-9892.1983.tb00373.x/abstract>>. Citado na página 9.

MOREIRA, J. M. d. S.; LEMGRUBER, E. F. O uso de dados de alta frequência na estimação da volatilidade e do valor em risco para o IBOVESPA. *Revista Brasileira de Economia*, v. 58, n. 1, p. 100–120, mar. 2004. ISSN 0034-7140. Disponível em: <http://www.scielo.br/scielo.php?script=sci_abstract&pid=S0034-71402004000100005&lng=en&nrm=iso&tlng=pt>. Citado na página 4.

SEO, B. Asymptotic distribution of the cointegrating vector estimator in error correction models with conditional heteroskedasticity. *Journal of Econometrics*, v. 137, n. 1, p. 68–111, mar. 2007. ISSN 0304-4076. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S030440760600039X>>. Citado 2 vezes nas páginas 3 e 6.

SERRA, T. Volatility spillovers between food and energy markets: A semiparametric approach. *Energy Economics*, v. 33, n. 6, p. 1155–1164, nov. 2011. ISSN 0140-9883. Disponível em: <<http://www.sciencedirect.com/science/article/pii/S0140988311000867>>. Citado 3 vezes nas páginas 2, 3 e 15.

SERRA, T. Price volatility in Niger millet markets. *Agricultural Economics*, v. 46, n. 4, p. 489–502, jul. 2015. ISSN 1574-0862. Disponível em: <<http://onlinelibrary.wiley.com/doi/10.1111/agec.12176/abstract>>. Citado na página 6.

SERRA, T.; GIL, J. M. Price volatility in food markets: can stock building mitigate price fluctuations? *European Review of Agricultural Economics*, v. 40, n. 3, p. 507–528, jul. 2013. ISSN 0165-1587. Disponível em: <<https://academic.oup.com/erae/article/40/3/507/485162/Price-volatility-in-food-markets-can-stock>>. Citado na página 3.

SERRA, T.; ZILBERMAN, D. Biofuel-related price transmission literature: A review. *Energy Economics*, v. 37, p. 141–151, maio 2013. ISSN 0140-9883. Disponível em: <<http://www.sciencedirect.com/science/article/pii/S0140988313000388>>. Citado na página 10.

SHAPIRO, S. S.; WILK, M. B. An analysis of variance test for normality (complete samples). *Biometrika*, v. 52, n. 3-4, p. 591–611, dez. 1965. ISSN 0006-3444. Disponível em: <<https://academic.oup.com/biomet/article-abstract/52/3-4/591/336553/An-analysis-of-variance-test-for-normality>>. Citado na página 10.

TSAY, R. S. *An Introduction to Analysis of Financial Data with R*. 1 edition. ed. Hoboken, N.J.: Wiley, 2012. ISBN 978-0-470-89081-3. Citado 3 vezes nas páginas 7, 9 e 10.

TSAY, R. S. *Multivariate Time Series Analysis: With R and Financial Applications*. [S.l.]: John Wiley & Sons, 2013. ISBN 978-1-118-61775-5. Citado 2 vezes nas páginas 13 e 15.

WU, F.; GUAN, Z.; MYERS, R. J. Volatility spillover effects and cross hedging in corn and crude oil futures. *Journal of Futures Markets*, v. 31, n. 11, p. 1052–1075, nov. 2011. ISSN 1096-9934. Disponível em: <<http://onlinelibrary.wiley.com/doi/10.1002/fut.20499/abstract>>. Citado 2 vezes nas páginas 1 e 3.

ZEILEIS, A.; GROTHENDIECK, G. zoo: S3 Infrastructure for Regular and Irregular Time Series. *Journal of Statistical Software*, v. 014, n. i06, p. 1–27, maio 2005. Disponível em: http://econpapers.repec.org/article/jssjstsof/v_3a014_3ai06.htm. Citado na página 7.

ZHANG, Z. et al. Ethanol, Corn, and Soybean Price Relations in a Volatile Vehicle-Fuels Market. *Energies*, v. 2, n. 2, p. 320–339, jun. 2009. Disponível em: <http://www.mdpi.com/1996-1073/2/2/320>. Citado na página 2.